

OpenAyane の実装計画

RDE 評価器に基づく意味変化監査機構の設計と段階的実装

Tomoyuki Kano
ZYX Corp 株式会社人工知能研究室
Independent Researcher
ORCID: [0009-0004-8213-4631](https://orcid.org/0009-0004-8213-4631)

Version 1.0 (2026-05-04)

Copyright © 2026 Tomoyuki Kano.

This paper is licensed under the Creative Commons Attribution 4.0 International License (CC BY 4.0).

Abstract

本稿は、OpenAyane を、生成 AI およびエージェント型 AI の出力・編集・実行過程における意味変化を監査する実装可能な機構として定式化する。大規模言語モデルは、文書やコードを厳密に保存しながら局所変更する機械ではなく、入力、履歴、指示、文脈に基づいて対象を再生成する。そのため、表面的には自然に見える出力の内部で、定義、制約、数値、参照、論旨、依存関係が静かに変化することがある。本稿ではこの現象を Silent ΔM と呼び、RDE (Resonant Deviation Evaluator) を中核評価器として導入する。RDE は Diff、Policy Filter、Validator、LLM Evaluator そのものではなく、変換前状態、期待された変換、実際の生成結果の差異を、タスク契約、文脈、関係履歴、制度的制約と照合し、意味変化の許可性と危険性を分類する評価器である。一方、OpenAyane は RDE を含み、Task Contract 生成、Generator 制御、Structural Diff、Semantic Delta、Policy Bridge、Safe Execution Runtime、AuditLog、RelationStore 更新、履歴参照ループを統合する関係的制御機構である。

キーワード： OpenAyane, RDE, Resonant Deviation Evaluator, Silent ΔM , 意味変化監査, Agent Safety, Relation Store

1 はじめに

生成 AI への委任が進むにつれ、「一部だけ直す」「主張を変えずに整える」「アルゴリズムを変えずにエラー処理を追加する」といった依頼において、表面上は自然でありながら、意味上重要な要素が静かに変化する問題が顕在化している。本稿では、この未署名の意味変化を Silent ΔM と呼ぶ。問題は、変化そのものではない。問題は、その変化が許可され、署名され、検証可能で、必要に応じて差し戻し可能であるかである。

2 RDE と OpenAyane の役割分担

本稿では、RDE と OpenAyane を明確に区別する。RDE は、生成系またはエージェント系が生む意味変化 ΔM を評価し、その変化が保存、許可された逸脱、軽微な副次的変化、疑義ある逸脱、重大な腐食、創造的逸脱のいずれに属するかを分類する評価器である。

一方、OpenAyane は RDE そのものではない。OpenAyane は、RDE を中核評価器として組み込み、Task Contract 生成、Generator 制御、Structural Diff、Semantic Delta、Policy Bridge、Safe Execution Runtime、AuditLog、RelationStore 更新、履歴参照ループを統合する機構である。したがって、RDE の問いは「この意味変化は何か」であり、OpenAyane の問いは「その評価結果を、どの制度的・関係的制御ループの中で、どのように扱うか」である。

3 形式モデル

文書または状態を D_t 、意味写像を $M(D_t)$ 、許可された変換を A_t 、実際の生成器による変換を $\hat{A}_t$ とする。期待される意味状態は

$$M_t^* = M(A_t(D_{t-1}))$$

であり、実際の意味状態は

$$\hat{M}_t = M(\hat{A}_t(D_{t-1}))$$

である。意味逸脱は

$$\Delta M_t = \hat{M}_t - M_t^*$$

として表される。ただし、RDE の目的は $\|\Delta M_t\|$ を単純に最小化することではない。創造的変換や設計変更では、大きな ΔM が正当な場合がある。RDE の目的は、 ΔM の大きさ、方向、対象、許可性、可逆性、検証可能性、制度的署名性を評価することである。

4 OpenAyane の実装フロー

OpenAyane の実装フローは、単線的な生成・評価・実行パイプラインではない。各実行後に AuditLog へ記録された Task Contract、Structural Diff、Semantic Delta、RDE 分類、Policy 決定、Rollback、人間レビュー結果は RelationStore へ集約され、trust、stability、context_affinity、drift pattern、generator reliability、document fragility として再構成される。これらの履歴状態は、次回以降の Intent 解析、Task Contract 生成、RDE 判定、Policy 判断に再入力される。




Figure 1: OpenAyane の実装フロー。RDE は意味変化 ΔM を分類する評価器であり、OpenAyane は Task Contract 生成、生成器制御、差分抽出、RDE 評価、Policy 判断、実行制御、AuditLog、RelationStore 更新、履歴参照ループを統合する機構である。

5 主要モジュール

OpenAyane は、Intent Parser、RelationContext Loader、Task Contract Builder、Generator Adapter、Structural Diff Engine、Semantic Delta Engine、RDE Core、Policy Bridge、Modification Control Flow、Safe Execution Runtime、AuditLog、RelationStore から構成される。

5.1 Task Contract

Task Contract は、曖昧な自然言語指示を、RDE が評価可能な契約へ変換する。許可された ΔM 、禁止された ΔM 、保護対象、出力形式、レビュー方針を明示することで、Generator の出力と RDE の評価基準を同時に規定する。

5.2 RDE Core

RDE Core は、Semantic Delta を Task Contract、Policy、Relation State と照合し、逸脱分類と推奨アクションを出す。ただし、RDE の required action は最終決定ではなく、Policy Bridge への推奨である。最終的な承認、差し戻し、停止、ロールバックは Policy Bridge が行う。

5.3 AuditLog と RelationStore

AuditLog は、過去に何が起きたかの不可逆的記録である。RelationStore は、その履歴から抽出された関係状態である。両者を分離することで、OpenAyane は単発の安全フィルタではなく、意味変化の履歴を通じて判断条件を更新する関係的制御ループとなる。

6 段階的実装計画

Phase 0 では、RDE 定義、Task Contract、逸脱分類、OpenAyane 既存モジュールとの対応を固定する。Phase 1 では、Markdown、JSON、Python を対象とする Structural RDE MVP を実装する。Phase 2 では Semantic Delta Engine と RelationStore 更新を導入する。Phase 3 では Agent Execution Gate を統合し、ツール実行前後の意味変化と権限を評価する。Phase 4 では Institution Layer へ接続し、PoP-UID、組織 Policy、外部監査、規範レジストリと連携する。

7 評価計画

評価は、生成品質ではなく、意味変化の検出、分類、承認制御、監査可能性、長期安定性を対象とする。Unit Test、Golden Test、Adversarial Test、Long-chain Test、Human Review Calibration を用いる。特に、Unauthorized Change Detection Rate、Critical Corruption Recall、Generator Self-report Mismatch Detection Rate、Long-chain Semantic Drift Detection Rate を重視する。

8 RDE 差異検証

本稿は、OpenAyane / RDE 設計思想および基本設計からの変換結果である。保存された要素は、RDE が Diff、Policy、LLM Evaluator そのものではなく、意味逸脱を裁定する評価器であるという定義である。変換された要素は、実装設計を研究論文として読める構造へ再配置した点である。補完された要素は、RDE と OpenAyane の役割分担、履歴参照ループ、評価計画、非機能要件である。未解決の要素は、context affinity の厳密な更新式、Semantic Delta の信頼性、Human Review Calibration の具体的データセット、Institution Layer の制度設計である。

9 結論

OpenAyane は、RDE を中核評価器として含む意味変化監査機構である。RDE は意味変化を分類する。OpenAyane は、その評価結果を実行制御、監査、履歴更新、次回判断へ接続する。したがって OpenAyane の核心は、単発の出力審査ではなく、AuditLog と RelationStore を通じて過去の ΔM を読み、現在の変換を評価し、未来の許可条件を更新する関係的制御ループにある。

References

- [1] Kano, Tomoyuki. 2026. 意味の非収束と共鳴条件：誤配に基づく *Resonanceverse* の基礎理論. Version 1.2. Zenodo. DOI: [10.5281/zenodo.20016805](https://doi.org/10.5281/zenodo.20016805).
- [2] Lewis, Patrick, et al. 2020. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.” arXiv:2005.11401.
- [3] Ouyang, Long, et al. 2022. “Training Language Models to Follow Instructions with Human Feedback.” *Advances in Neural Information Processing Systems*.
- [4] Yao, Shunyu, et al. 2022. “ReAct: Synergizing Reasoning and Acting in Language Models.” arXiv:2210.03629.
- [5] Wilkinson, Mark D., et al. 2016. “The FAIR Guiding Principles for Scientific Data Management and Stewardship.” *Scientific Data* 3:160018.